

PROGRAMMAZIONE NON LINEARE

**OTTIMIZZAZIONE NON LINEARE IN PIÙ
VARIABILI**



Come cerchiamo i punti massimo/minimo?

Soluzione analitica

- Poniamo il gradiente della funzione uguale a zero per cercare i punti stazionari ovvero i punti candidati ad essere massimo o minimo

$$\nabla f = 0$$

In questo caso dovremmo risolvere n equazioni ($\frac{\partial f}{\partial x_i} = 0$) in n incognite $x_1, x_2, \dots, x_n$

- Una volta trovati i punti candidati, valutiamo la matrice Hessiana della funzione in quei punti:
 - Se la matrice è definita positiva allora il punto candidato è minimo
 - Se la matrice è definita negativa allora il punto candidato è di massimo

In questo caso dovremo calcolare il segno degli n autovalori



Esempio

- Consideriamo il seguente problema di ottimizzazione in tre variabili

$$\min f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

- Calcoliamo il gradiente di tale funzione

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 + 1 - x_2 \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$



Esempio

- Ora poniamo a zero il gradiente

$$\nabla f = 0 \quad \longrightarrow \quad \begin{cases} 2x_1 + 1 - x_2 = 0 \\ -x_1 + 2x_2 - x_3 = 0 \\ -x_2 + 2x_3 + 1 = 0 \end{cases}$$

- Otteniamo un sistema lineare di 3 equazioni in 3 incognite che ha come soluzione (unica)

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

- Abbiamo quindi un solo punto candidato dove dobbiamo andare a valutare la matrice Hessiana



Esempio

$$\nabla f = \begin{bmatrix} 2x_1 + 1 - x_2 \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

- Calcoliamo le derivate seconde della funzione

Derivate seconde pure

$$\frac{\partial^2 f}{\partial x_1^2} = 2$$

$$\frac{\partial^2 f}{\partial x_2^2} = 2$$

$$\frac{\partial^2 f}{\partial x_3^2} = 2$$

Derivate seconde miste

$$\frac{\partial^2 f}{\partial x_1 \partial x_2} = -1$$

$$\frac{\partial^2 f}{\partial x_1 \partial x_3} = 0$$

$$\frac{\partial^2 f}{\partial x_2 \partial x_3} = -1$$

- Notiamo che essendo simmetrica la matrice Hessiana dobbiamo calcolare solo le 3 derivate pure e 3 della 6 derivate miste

DOMANDA Nel caso di n variabili, quante derivate seconde bisogna calcolare? n pure $+\sum_{i=1}^{n-1}(n-i)$ miste



Esempio

- Una volta calcolate le derivate seconde, possiamo costruire la matrice Hessiana

$$\nabla f = \begin{bmatrix} 2x_1 + 1 - x_2 \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

$$H_f(x_1, x_2, x_3) = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

- Notiamo che in questo caso la matrice Hessiana ottenuta non dipende dal punto considerato
- Gli autovalori di tale matrice sono 3 e corrispondono a:

$$\lambda_1 = 3.414 \quad \lambda_2 = 0.586 \quad \lambda_3 = 2$$

- Tutti gli autovalori sono positivi $\rightarrow$ la matrice Hessiana è definita positiva $\rightarrow$ il punto considerato è di minimo



Osservazioni

- Nel precedente esempio la funzione considerata era convessa quindi il punto ottenuto di minimo locale corrisponde anche al punto (unico) di minimo globale
- In generale, se non abbiamo informazioni globali riguardo la convessità o meno di una funzione non possiamo stabilire se un punto di minimo/massimo locale è anche globale
- Nel precedente esempio, per cercare i punti di minimo/massimo abbiamo posto il gradiente uguale a zero, ottenendo 3 equazioni **lineari** in 3 incognite
- Nel caso generale le equazioni che otteniamo non sono lineari e possono risultare particolarmente difficili da risolvere analiticamente

Esempio

$$f(x_1, x_2, x_3) = \sin(x_1^2 + x_2^2) e^{x_3^2 - \sqrt{\log x_2^2}}$$

- In questo caso come possiamo trovare i punti di minimo/massimo locali/globali di questa funzione?



Algoritmi numerici per l'ottimizzazione non lineare

- Così come per il caso unidimensionale, sono disponibili vari algoritmi di ottimizzazione non lineare, tra cui:
 - metodo del **gradiente (steepest descent)**
 - metodo di **Newton**
- Gli algoritmi che consideriamo appartengono all'insieme delle strategie di tipo **line-search**, le quali generano una successione di punti x_k all'interno dello spazio R^n in modo che il punto x_{k+1} è ottenuto a partire dal punto x_k muovendosi lungo una **direzione di salita** (nel caso di massimo) o **di discesa** (nel caso di minimo)

Esempio

Consideriamo la funzione

$$f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

Nel punto $(0,0,0)$ si ha $f(x) = 0$, mentre il gradiente $\nabla f = \begin{bmatrix} 2x_1 + 1 - x_2 \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$ vale $\nabla f = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$

- Se dal punto $(0,0,0)$ ci spostiamo (di poco) lungo la direzione $\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ allora il valore della funzione cresce
- Se dal punto $(0,0,0)$ ci spostiamo (di poco) lungo la direzione $-\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ allora il valore della funzione decresce



Algoritmo per un generico metodo line-search

- Consideriamo una generica funzione $f: R^n \rightarrow R$, ed un generico punto $x \in R^n$ in cui la funzione risulti differenziabile.
- Se vogliamo cercare un generico punto di minimo della funzione f , possiamo usare la seguente strategia

- poniamo $k = 0$ e consideriamo un generico punto x^k e
- determiniamo una direzione di discesa d^k
- cerchiamo un nuovo punto x^{k+1} lungo la direzione d^k

$$x^{k+1} = x^k + \alpha^k d^k$$

dove k è la generica iterazione e $\alpha^k > 0$ è una quantità scalare chiamata **step-size**



Lo step size

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha^k \mathbf{d}^k$$

- Dati il punto di partenza $\mathbf{x}^k$ e la direzione di ricerca $\mathbf{d}^k$, come si calcola lo step size?

Osservazione

- Vogliamo minimizzare/massimizzare il valore della funzione $f(\mathbf{x}^{k+1}) = f(\mathbf{x}^k + \alpha^k \mathbf{d}^k)$ ovvero la restrizione della funzione $f(\mathbf{x})$ lungo la direzione $\mathbf{d}^k$
- Notiamo che $\mathbf{x}^k$ (punto corrente) e $\mathbf{d}^k$ (direzione corrente) sono fissate → la sola variabile risulta essere α^k
- Per trovare α^k possiamo allora porre

$$\frac{df(\mathbf{x}^k + \alpha^k \mathbf{d}^k)}{d\alpha^k} = 0$$

- ed usare un metodo di minimizzazione/massimizzazione per funzioni in una variabile per trovare α^k ottimale




Il metodo del gradiente

➤ Nel metodo del gradiente viene utilizzata:

- come direzione di crescita $\mathbf{d}^k = \nabla f(\mathbf{x}^k)$ per problemi di massimo
- come direzione di decrescita $\mathbf{d}^k = -\nabla f(\mathbf{x}^k)$ per problemi di minimo

$$\mathbf{x}^{k+1} = \mathbf{x}^k \pm \alpha^k \nabla f(\mathbf{x}^k)$$

L'idea di tale metodo è che il gradiente la direzione di salita/discesa più ripida della funzione



Algoritmo del gradiente

1. Poniamo $k = 0$ e consideriamo un generico punto x^k

2. Calcoliamo il gradiente di $f(x^k)$

$$\nabla f(x^k)$$

3. Poniamo $d^k = -\nabla f(x^k)$ per problemi di minimo e $d^k = +\nabla f(x^k)$ per problemi di massimo

4. Poniamo $x^{k+1} = x^k + \alpha^k \nabla f(x^k)$

5. Calcoliamo $\alpha^k > 0$ come soluzione di

$$f'(x^k + \alpha^k \nabla f(x^k)) = 0$$

utilizzando un metodo di ottimizzazione per funzioni in una variabile

6. Criterio di arresto:

se $|f(x^{k+1}) - f(x^k)| < \epsilon_1$ o $\|\nabla f(x^{k+1})\| < \epsilon_2$ allora STOP,

altrimenti eseguiamo una nuova iterazione del metodo, poniamo $k = k + 1$ e torniamo al punto 2



Esempio

- Risolviamo l'esempio precedente utilizzando il metodo del gradiente

$$\min f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

- Poniamo $k = 0$, $\epsilon_1 = 0.01$ e $\epsilon_2 = 0.1$

- Consideriamo come punto iniziale l'origine

$$\mathbf{x}^0 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

- Calcoliamo il gradiente della funzione nel punto iniziale

$$\nabla f(\mathbf{x}) = [2x_1 + (1 - x_2) \quad -x_1 + 2x_2 - x_3 \quad -x_2 + 2x_3 + 1]$$



Prima iterazione

- Valutiamo il gradiente nel punto iniziale per ottenere la direzione di discesa

$$\begin{aligned}\mathbf{d}^0 &= -\nabla f(\mathbf{x}^0) = -[2(0) + 1 - 0 \quad -0 + 0 - 0 \quad -0 + 0 + 1] \\ &= -[1 \quad 0 \quad 1] = [-1 \quad 0 \quad -1]\end{aligned}$$

- Il nuovo punto $\mathbf{x}^1$ è dato da

$$\mathbf{x}^1 = [0 \quad 0 \quad 0] + \alpha^0 \cdot [-1 \quad 0 \quad -1]$$

- Ora dobbiamo calcolare α^0



Prima iterazione

$$\mathbf{x}^1 = [0 \quad 0 \quad 0] + \alpha^0 \cdot [-1 \quad 0 \quad -1] = [-\alpha^0, 0, -\alpha^0]$$

- Calcoliamo il punto di minimo della funzione f lungo la direzione di discesa $\mathbf{d}^0$

$$f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

$$f(\mathbf{x}^1) = (-\alpha^0)^2 + (-\alpha^0)(1) + 0 - 0 + (-\alpha^0)^2 + (-\alpha^0) = 2(\alpha^0)^2 - 2(\alpha^0)$$

$$\frac{df(\mathbf{x}^1)}{d\alpha^0} = 4(\alpha^0) - 2$$

- Otteniamo come punto di minimo

$$4(\alpha^0) = 2 \implies \alpha^0 = \frac{2}{4} = \frac{1}{2}$$

- Il nuovo punto $\mathbf{x}^1$ è dato quindi da

$$\mathbf{x}^1 = [0 \quad 0 \quad 0] + \alpha^0 \cdot [-1 \quad 0 \quad -1]$$

$$\mathbf{x}^1 = \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix}$$



Criterio di arresto

- Verifichiamo ora se uno dei criteri di convergenza è soddisfatto

Primo criterio

- Valutiamo $|f(\mathbf{x}^1) - f(\mathbf{x}^0)|$
- $f(\mathbf{x}^0) = 0$
- $f(\mathbf{x}^1) = -\frac{1}{2}$
- $|f(\mathbf{x}^1) - f(\mathbf{x}^0)| = 0.5 > \epsilon_1$

Secondo criterio

- Valutiamo $\|\nabla f(\mathbf{x}^1)\|$
- $\nabla f(\mathbf{x}^1) = [0 \quad 1 \quad 0]$
- $\|\nabla f(\mathbf{x}^1)\| = \sqrt{(0)^2 + (1)^2 + (0)^2} = 1 > \epsilon_2$

- Non possiamo terminare l'algoritmo e dobbiamo eseguire una nuova iterazione del metodo

$$\mathbf{x}^0 = [0 \quad 0 \quad 0]$$

$$\mathbf{x}^1 = \left[-\frac{1}{2} \quad 0 \quad -\frac{1}{2}\right]$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$



Seconda iterazione

- Cerchiamo ora un nuovo punto $\mathbf{x}^2$, calcolando la nuova direzione di discesa $\mathbf{d}^1$

$$\mathbf{d}^1 = -\nabla f(\mathbf{x}^1) = -\begin{bmatrix} -1 + 1 + 0 & \frac{1}{2} + 0 + \frac{1}{2} & 0 - 1 + 1 \end{bmatrix}$$

$$\mathbf{d}^1 = \begin{bmatrix} 0 & -1 & 0 \end{bmatrix}$$

- il nuovo punto $\mathbf{x}^2$ sarà dato da

$$\mathbf{x}^2 = \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix} + \alpha^1 \cdot \begin{bmatrix} 0 & -1 & 0 \end{bmatrix}$$

$$= \begin{bmatrix} -\frac{1}{2} & -\alpha^1 & -\frac{1}{2} \end{bmatrix}$$

- Ora dobbiamo calcolare α^1



Seconda iterazione

- Calcoliamo il nuovo punto di minimo della funzione lungo la nuova direzione di discesa per stimare α^1

$$\begin{aligned} f(\mathbf{x}^2) &= \frac{1}{4} + \left(-\frac{1}{2}\right)(1 + \alpha^1) + (\alpha^1)^2 - (\alpha^1)\left(\frac{1}{2}\right) + \frac{1}{4} - \frac{1}{2} \\ &= (\alpha^1)^2 - \alpha^1 - \frac{1}{2} \end{aligned}$$

- Ottenendo il nuovo valore α^1

$$\frac{df(\mathbf{x}^1)}{d\alpha^1} = 2(\alpha^1) - 1 \qquad 2(\alpha^1) = 1 \implies \alpha^1 = \frac{1}{2}$$

- Il nuovo punto $\mathbf{x}^2$ è dato quindi da

$$\begin{aligned} \mathbf{x}^2 &= \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix} + \alpha^1 \cdot [0 \quad -1 \quad 0] \\ \mathbf{x}^2 &= \begin{bmatrix} -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix} \end{aligned}$$



Criterio di arresto

- Verifichiamo ora se uno dei criteri di convergenza è soddisfatto

Primo criterio

- Valutiamo $|f(\mathbf{x}^2) - f(\mathbf{x}^1)|$
- $f(\mathbf{x}^1) = -\frac{1}{2}$
- $f(\mathbf{x}^2) = -0.75$
- $|f(\mathbf{x}^2) - f(\mathbf{x}^1)| = 0.25 > \epsilon_1$

Secondo criterio

- Valutiamo $\|\nabla f(\mathbf{x}^2)\|$
- $\nabla f(\mathbf{x}^2) = \begin{bmatrix} \frac{1}{2} & 0 & \frac{1}{2} \end{bmatrix}$
- $\|\nabla f(\mathbf{x}^2)\| = 0.7071 > \epsilon_2$

$$\mathbf{x}^1 = \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix}$$

$$\mathbf{x}^2 = \begin{bmatrix} -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

- Non possiamo terminare l'algoritmo e dobbiamo eseguire una nuova iterazione del metodo



Terza iterazione

- Cerchiamo ora un nuovo punto, calcolando la nuova direzione di discesa $\mathbf{d}^2$

$$\mathbf{d}^2 = -\nabla f(\mathbf{x}^2) = -\begin{bmatrix} -1 + 1 + \frac{1}{2} & \frac{1}{2} - 1 + \frac{1}{2} & \frac{1}{2} - 1 + 1 \end{bmatrix}$$

$$\mathbf{d}^2 = \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix}$$

- il nuovo punto $\mathbf{x}^3$ sarà dato da

$$\mathbf{x}^3 = \begin{bmatrix} -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix} + \alpha^2 \cdot \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix}$$

$$= \begin{bmatrix} -\frac{1}{2}(\alpha^2 + 1) & -\frac{1}{2} & -\frac{1}{2}(\alpha^2 + 1) \end{bmatrix}$$

- Ora dobbiamo calcolare α^2



Terza iterazione

- Calcoliamo il nuovo punto di minimo della funzione lungo la nuova direzione di discesa d^2 per stimare α^2

$$f(\mathbf{x}^3) = \frac{1}{2}(\alpha^2 + 1)^2 - \frac{3}{2}(\alpha^2 + 1) + \frac{1}{4}$$

$$\frac{df(\mathbf{x}^3)}{d\alpha^2} = (\alpha^2 + 1) - \frac{3}{2}$$

- Otteniamo il nuovo valore α^2

$$(\alpha^2 + 1) = \frac{3}{2} \Rightarrow \alpha^2 = \frac{1}{2}$$

- Il nuovo punto $\mathbf{x}^3$ è dato quindi da

$$\mathbf{x}^3 = \begin{bmatrix} -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix} + \alpha^2 \cdot \begin{bmatrix} -\frac{1}{2} & 0 & -\frac{1}{2} \end{bmatrix}$$

$$\mathbf{x}^3 = \begin{bmatrix} -\frac{3}{4} & -\frac{1}{2} & -\frac{3}{4} \end{bmatrix}$$



Criterio di arresto

- Verifichiamo ora se uno dei criteri di convergenza è soddisfatto

Primo criterio

- Valutiamo $|f(\mathbf{x}^3) - f(\mathbf{x}^2)|$
- $f(\mathbf{x}^2) = -0.75$
- $f(\mathbf{x}^3) = -0.875$
- $|f(\mathbf{x}^3) - f(\mathbf{x}^2)| = 0.125 > \epsilon_1$

Secondo criterio

- Valutiamo $\|\nabla f(\mathbf{x}^3)\|$
- $\nabla f(\mathbf{x}^3) = \begin{bmatrix} 0 & \frac{1}{2} & 0 \end{bmatrix}$
- $\|\nabla f(\mathbf{x}^3)\| = 0.5 > \epsilon_2$

$$\mathbf{x}^2 = \begin{bmatrix} -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

$$\mathbf{x}^3 = \begin{bmatrix} -\frac{3}{4} & -\frac{1}{2} & -\frac{3}{4} \end{bmatrix}$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

- Non possiamo terminare l'algoritmo e dobbiamo eseguire una nuova iterazione del metodo



Quarta iterazione

- Cerchiamo ora un nuovo punto, calcolando la nuova direzione di discesa $\mathbf{d}^3$

$$\mathbf{d}^3 = -\nabla f(\mathbf{x}^3) = -\begin{bmatrix} 0 & \frac{1}{2} & 0 \end{bmatrix} = \begin{bmatrix} 0 & -\frac{1}{2} & 0 \end{bmatrix}$$

- il nuovo punto $\mathbf{x}^4$ sarà dato da

$$\begin{aligned}\mathbf{x}^4 &= \begin{bmatrix} -\frac{3}{4} & -\frac{1}{2} & -\frac{3}{4} \end{bmatrix} + \alpha^3 \cdot \begin{bmatrix} 0 & -\frac{1}{2} & 0 \end{bmatrix} \\ &= \begin{bmatrix} -\frac{3}{4} & -\frac{1}{2}(\alpha^3 + 1) & -\frac{3}{4} \end{bmatrix}\end{aligned}$$

- Ora dobbiamo calcolare α^3



Quarta iterazione

- Calcoliamo il nuovo punto di minimo della funzione lungo la nuova direzione di discesa $\mathbf{d}^3$ per stimare α^3

$$f(\mathbf{x}^4) = \frac{1}{4}(\alpha^3 + 1)^2 - \frac{3}{2}(\alpha^3) - \frac{3}{2}$$

$$\frac{df(\mathbf{x}^4)}{d\alpha^3} = \frac{1}{2}(\alpha^3 + 1) - \frac{3}{2} = 0$$

- Otteniamo il nuovo valore α^3

$$\Rightarrow \alpha^3 = \frac{5}{4}$$

- il nuovo punto $\mathbf{x}^4$ risulta quindi

$$\mathbf{x}^4 = \begin{bmatrix} -\frac{3}{4} & -\frac{1}{2} & -\frac{3}{4} \end{bmatrix} + \begin{bmatrix} 0 & -\frac{5}{8} & 0 \end{bmatrix}$$

$$\mathbf{x}^4 = \begin{bmatrix} -\frac{3}{4} & -\frac{9}{8} & -\frac{3}{4} \end{bmatrix}$$



Criterio di arresto

- Verifichiamo ora se uno dei criteri di convergenza è soddisfatto

Primo criterio

- Valutiamo $|f(\mathbf{x}^4) - f(\mathbf{x}^3)|$
- $f(\mathbf{x}^3) = -0.875$
- $f(\mathbf{x}^4) = -0.7969$
- $|f(\mathbf{x}^4) - f(\mathbf{x}^3)| = 0.0781 > \epsilon_1$

Secondo criterio

- Valutiamo $\|\nabla f(\mathbf{x}^4)\|$
- $\nabla f(\mathbf{x}^4) = \begin{bmatrix} -\frac{5}{8} & \frac{3}{4} & -\frac{5}{8} \end{bmatrix}$
- $\|\nabla f(\mathbf{x}^4)\| = 1.1592 > \epsilon_2$

- Non possiamo terminare l'algoritmo e dobbiamo eseguire una nuova iterazione del metodo

$$\mathbf{x}^3 = \begin{bmatrix} \frac{3}{4} & -\frac{1}{2} & -\frac{3}{4} \end{bmatrix}$$

$$\mathbf{x}^4 = \begin{bmatrix} \frac{3}{4} & -\frac{9}{8} & -\frac{3}{4} \end{bmatrix}$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$



Quinta iterazione

- Cerchiamo ora un nuovo punto, calcolando la nuova direzione di discesa $\mathbf{d}^4$

$$\mathbf{d}^4 = -\nabla f(\mathbf{x}^4) = -\begin{bmatrix} \frac{5}{8} & -\frac{3}{4} & \frac{5}{8} \end{bmatrix} = \begin{bmatrix} -\frac{5}{8} & \frac{3}{4} & -\frac{5}{8} \end{bmatrix}$$

- il nuovo punto $\mathbf{x}^5$ sarà dato da

$$\begin{aligned} \mathbf{x}^5 &= \begin{bmatrix} -\frac{3}{4} & -\frac{9}{8} & -\frac{3}{4} \end{bmatrix} + \alpha^4 \cdot \begin{bmatrix} -\frac{5}{8} & \frac{3}{4} & -\frac{5}{8} \end{bmatrix} \\ &= \begin{bmatrix} -\frac{1}{4}(3 + \frac{5}{2}\alpha^4) & -\frac{3}{4}(\frac{3}{2} - \alpha^4) & -\frac{1}{4}(3 + \frac{5}{2}\alpha^4) \end{bmatrix} \end{aligned}$$

- Ora dobbiamo calcolare α^4



Quinta iterazione

- Calcoliamo il nuovo punto di minimo della funzione lungo la nuova direzione di discesa $\mathbf{d}^4$ per stimare α^4

$$f(\mathbf{x}^5) = \frac{73}{32}(\alpha^4)^2 - \frac{43}{32}\alpha^4 - \frac{51}{64}$$

$$\frac{df(\mathbf{x}^5)}{d\alpha^4} = \frac{73}{16}\alpha^4 - \frac{43}{32} = 0$$

- Otteniamo il nuovo valore α^4

$$\Rightarrow \alpha^4 = 43/146$$

- il nuovo punto $\mathbf{x}^5$ risulta quindi

$$\mathbf{x}^5 = \begin{bmatrix} -\frac{3}{4} & -\frac{9}{8} & -\frac{3}{4} \end{bmatrix} + \frac{43}{146} \cdot \begin{bmatrix} -\frac{5}{8} & \frac{3}{4} & -\frac{5}{8} \end{bmatrix}$$

$$\mathbf{x}^5 = \begin{bmatrix} -\frac{1091}{1168} & -\frac{66}{73} & -\frac{1091}{1168} \end{bmatrix}$$



Criterio di arresto

➤ Verifichiamo ora se uno dei criteri di convergenza è soddisfatto

Primo criterio

- Valutiamo $|f(\mathbf{x}^4) - f(\mathbf{x}^3)|$
- $f(\mathbf{x}^3) = -0.875$
- $f(\mathbf{x}^4) = -0.9948$
- $|f(\mathbf{x}^4) - f(\mathbf{x}^3)| = 0.1198 > \epsilon_1$

Secondo criterio

- Valutiamo $\|\nabla f(\mathbf{x}^5)\|$
- $\nabla f(\mathbf{x}^5) = \begin{bmatrix} \frac{21}{584} & \frac{35}{584} & \frac{21}{584} \end{bmatrix}$
- $\|\nabla f(\mathbf{x}^5)\| = 0.0786 < \epsilon_2$

➤ Possiamo terminare l'algoritmo essendo rispettato il secondo criterio di arresto

$$\mathbf{x}^4 = \begin{bmatrix} -\frac{3}{4} & -\frac{9}{8} & -\frac{3}{4} \end{bmatrix}$$

$$\mathbf{x}^5 = \begin{bmatrix} -\frac{1091}{1168} & -\frac{66}{73} & -\frac{1091}{1168} \end{bmatrix}$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$



Riassumendo

$$\min f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

Iterazione 0

$$\mathbf{x}^0 = [0 \quad 0 \quad 0]$$

$$\|\nabla f(\mathbf{x}^0)\| = \sqrt{2}$$

Iterazione 1

$$\mathbf{x}^1 = \left[-\frac{1}{2} \quad 0 \quad -\frac{1}{2}\right]$$

$$\|\nabla f(\mathbf{x}^1)\| = 1$$

Iterazione 2

$$\mathbf{x}^2 = \left[-\frac{1}{2} \quad -\frac{1}{2} \quad -\frac{1}{2}\right]$$

$$\|\nabla f(\mathbf{x}^2)\| = 0.7071$$

Iterazione 3

$$\mathbf{x}^3 = \left[-\frac{3}{4} \quad -\frac{1}{2} \quad -\frac{3}{4}\right]$$

$$\|\nabla f(\mathbf{x}^3)\| = 0.5$$

Iterazione 4


$$\mathbf{x}^4 = \left[-\frac{3}{4} \quad -\frac{9}{8} \quad -\frac{3}{4}\right]$$

$$\|\nabla f(\mathbf{x}^4)\| = 1.1592$$

Iterazione 5

$$\mathbf{x}^5 = \left[-\frac{1091}{1168} \quad -\frac{66}{73} \quad -\frac{1091}{1168}\right]$$

$$\|\nabla f(\mathbf{x}^5)\| = 0.0786$$



Metodo di Newton


- Nel metodo di Newton approssimiamo nell'intorno del punto corrente, la funzione $f(x)$ con una funzione quadratica che viene ottimizzata per ottenere un nuovo punto

$$f(x^k + \Delta x) = f(x^k) + \nabla f(x^k)\Delta x + \frac{1}{2}\Delta x H_f(x^k)\Delta x$$

Sviluppo in serie di Taylor per funzioni a più variabili

- Cerco una direzione di miglioramento che ottimizza la funzione nel nuovo punto $(x^k + \Delta x)$

$$\frac{\partial f(x^k + \Delta x)}{\partial \Delta x} = 0$$



$$H_f(x^k)\Delta x = -\nabla f(x^k)$$

- **Newton step**, muove ad un punto stazionario del 2° ordine dello sviluppo in serie di Taylor della funzione $f(x^k)$



Metodo di Newton

Tenendo presente che $\Delta x = x^{k+1} - x^k$

1. $k=0$; Scegliamo un punto iniziale, $\mathbf{x}^k$
2. Calcoliamo $\nabla f(\mathbf{x}^k)$ e $H_f(\mathbf{x}^k)^{-1}$
3. Calcoliamo il nuovo punto usando la seguente equazione

$$\mathbf{x}^{k+1} = \mathbf{x}^k - H_f(\mathbf{x}^k)^{-1} \cdot \nabla f(\mathbf{x}^k)$$

4. Usiamo i criteri di convergenza visti prima per il metodo del gradiente. Se non vengono superati, $k=k+1$ e torniamo al punto 2



Osservazioni

- Il metodo di Newton utilizza sia il gradiente che la matrice Hessiana ad ogni iterazione
- Il metodo di Newton (se) converge, converge molto più velocemente del metodo del gradiente, ma ogni iterazione richiede uno sforzo computazionale maggiore
 - nel caso di una funzione con 100 variabili si dovrebbe invertire una matrice 100×100 ad ogni iterazione
- Nel caso di funzioni quadratiche, il metodo di Newton converge in una iterazione (questo perché l'approssimazione che fa della funzione è quadratica!)
- Nel caso di funzione più complesse, la matrice Hessiana risulta più complessa da calcolare



Esempio

- Risolviamo l'esempio precedente utilizzando il metodo di Newton

$$\min f(x_1, x_2, x_3) = x_1^2 + x_1(1 - x_2) + x_2^2 - x_2x_3 + x_3^2 + x_3$$

- Poniamo $k = 0$, $\epsilon_1 = 0.01$ e $\epsilon_2 = 0.1$

- Consideriamo come punto iniziale l'origine

$$\mathbf{x}^0 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

- Calcoliamo il gradiente della funzione nel punto iniziale

$$\begin{aligned} \nabla f(\mathbf{x}) &= [2x_1 + (1 - x_2) \quad -x_1 + 2x_2 - x_3 \quad -x_2 + 2x_3 + 1] \\ &= [1 \quad 0 \quad 1] \end{aligned}$$



Calcoliamo la matrice Hessiana

- La matrice Hessiana per un generico punto è data da

$$H_f(\mathbf{x}) = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

- Calcoliamo la matrice inversa

$$[H_f(\mathbf{x})]^{-1} = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}^{-1} = \begin{bmatrix} 3/4 & 1/2 & 1/4 \\ 1/2 & 1 & 1/2 \\ 1/4 & 1/2 & 3/4 \end{bmatrix}$$



Prima iterazione

- Il nuovo punto è dato da

$$\mathbf{x}^1 = \mathbf{x}^0 - [H_f(\mathbf{x}^0)]^{-1} \cdot \nabla f(\mathbf{x}^0) = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} \frac{3}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{2} & 1 & \frac{1}{2} \\ \frac{1}{4} & \frac{1}{2} & \frac{3}{4} \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

- ovvero

$$\mathbf{x}^1 = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

In una iterazione abbiamo trovato il punto di minimo!!!

- Infatti il gradiente nel nuovo punto è dato da

$$\nabla f(\mathbf{x}^1) = [-2+1+1 \quad 1-2+1 \quad 1-2+1] = [0 \quad 0 \quad 0]$$



